DANTE–MAMBA

Arquitetura de Machine Learning para Continuidade de Estado em Agentes de IA Locais

Documento do Projeto • Versão 1.0

Outubro de 2026

Ordem	Função	Nomes dos participantes do projeto	Github
1		Jorge Rizzini de Castro FIlho	https://github.com/JorgeRizzini
2		Laísa Eugênio Severiano	https://github.com/LaisaEugenio
3		Otávio Augusto de Lima Beato	https://github.com/coldguto22
4			
5			

Lista de Figuras

Figura 2 — Fluxo de persistência do estado recorrente
Figura 1 — Arquitetura experimental Dante–Mamba

Lista de Quadros

Quadro 2 — Etapas e entregáveis do experimento
Quadro 1 — Critérios de agência e hipóteses observáveis

Lista de Tabelas

Tabela 2 — Métricas e protocolos de avaliação
Tabela 1 — Comparação entre configuração atual e proposta

Lista de Siglas

ODS — Objetivos de Desenvolvimento Sustentável
API — Application Programming Interface
GPU — Graphics Processing Unit (unidade de processamento gráfico)
HiPPO — High-order Polynomial Projection Operators
SSM — State Space Model (modelo de espaço de estados)
RAG — Retrieval-Augmented Generation (geração aumentada por recuperação)
OCR — Optical Character Recognition (reconhecimento óptico de caracteres)
ML — Machine Learning (aprendizado de máquina)
LLM — Large Language Model (modelo de linguagem de grande porte)
IA — Inteligência Artificial

1. Introdução

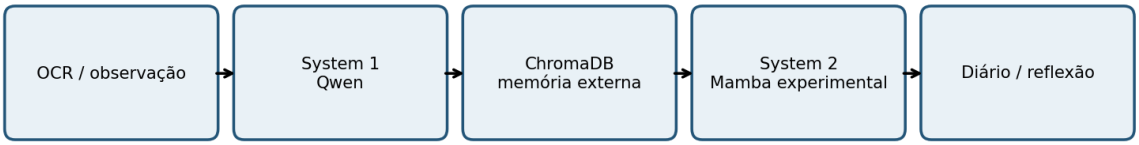


Figura 1 — Arquitetura de integração experimental do Dante–Mamba. Fonte: elaboração própria (2026).

O Dante é um sistema experimental de IA local que observa a tela por OCR, produz pensamentos e reflexões, registra um diário e recupera memórias pelo ChromaDB. Utiliza Qwen2.5:3b no System 1 e Llama 3.1:8b no System 2. A proposta é avaliar um modelo da família Mamba com estado recorrente preservado entre ciclos, como mecanismo complementar à memória vetorial. O trabalho se relaciona ao ODS 9, ao investigar infraestrutura computacional e inovação em modelos eficientes.

1.1. Problemática

A pesquisa não parte da premissa de que um estado persistente produz consciência ou agência. A hipótese testável é que a preservação controlada do estado recorrente melhora continuidade contextual, consistência de prioridades e dependência do histórico, em comparação a reinicializações sem estado.

Critério	Hipótese operacional	Indicador
Individualidade	Maior continuidade entre ciclos	Consistência de referências e memória
Normatividade	Maior estabilidade de prioridades	Concordância de decisões em cenários repetidos
Assimetria	Histórico altera respostas a estímulos iguais	Diferença controlada entre trajetórias

Quadro 1 — Critérios de agência e hipóteses observáveis. Fonte: elaboração própria (2026).

Os ciclos de inferência do Dante dependem de prompts e memórias externas; não há, na configuração atual, garantia de continuidade de estado recorrente dentro do modelo. Busca-se verificar se a persistência controlada desse estado melhora a coerência temporal sem comprometer desempenho, privacidade ou estabilidade.

1.2. Objetivo geral

Projetar e avaliar uma integração experimental de Mamba ao Dante, com persistência e restauração explícitas do estado de inferência, comparando seus resultados aos modelos atuais.

1.2.1. Objetivos específicos

Mapear a arquitetura existente; selecionar backend compatível; implementar checkpoint, reset e isolamento de estado; comparar inicialização zerada, burn-in e restauração; medir retenção, consistência, latência, memória e robustez.

1.2.2. Metodologia de desenvolvimento para projeto

Serão utilizadas sequências sintéticas e consentidas de observação. Cada cenário será repetido com sementes e configurações documentadas, comparando (A) Transformer com RAG, (B) Mamba com reset a cada ciclo, (C) Mamba com estado persistente e (D) Mamba persistente com burn-in. HiPPO será avaliado apenas quando suportado pelo modelo e backend selecionados.

Configuração	Estado entre ciclos	Recuperação externa
Dante atual: Qwen/Llama	Não preservado como estado recorrente	ChromaDB
Mamba com reset	Reiniciado	Opcional
Mamba persistente	Checkpoint restaurado	ChromaDB
Mamba + burn-in	Checkpoint + aquecimento contextual	ChromaDB

Tabela 1 — Comparação entre configuração atual e proposta. Fonte: elaboração própria (2026).

Pesquisa aplicada e experimental, com abordagem quantitativa e qualitativa. Os testes utilizarão sequências controladas de OCR e memória, cenários com históricos diferentes e repetição de execuções. O baseline será o Dante atual, sem alteração de seu ambiente principal.

2. Planejamento de metas

Fase	Atividade	Entregável
1	Mapear pipeline e dependências	Diagrama e requisitos
2	Selecionar backend com acesso a estados	Prova de conceito
3	Implementar checkpoint, isolamento e reset	Protótipo instrumentado
4	Integrar ChromaDB e burn-in	Pipeline experimental
5	Executar benchmarks e análise	Relatório comparativo

Quadro 2 — Etapas e entregáveis do experimento. Fonte: elaboração própria (2026).

Fase 1 — levantamento da arquitetura Dante e dos contratos de inferência. Fase 2 — escolha de modelo Mamba e backend com acesso ao estado recorrente. Fase 3 — protótipo isolado com reset, checkpoint e restauração. Fase 4 — integração experimental ao System 2, mantendo os modelos atuais como referência. Fase 5 — comparação de continuidade, qualidade, recursos e segurança. Fase 6 — análise dos resultados e documentação.

3. Planejamento do modelo de Machine Learning

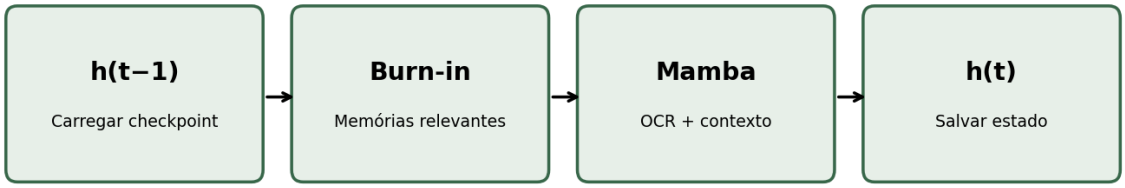


Figura 2 — Ciclo de carregamento, atualização e salvamento do estado recorrente. Fonte: elaboração própria (2026).

O checkpoint deverá registrar versão do modelo, tokenizer, dimensões e tipo do estado, identificação da sessão e metadados de integridade. O estado não deve ser compartilhado inadvertidamente entre usuários, nem reutilizado após mudanças incompatíveis de pesos ou configuração. A continuidade deve ser medida, e não presumida.

Métrica	Procedimento	Interpretação
Latência por ciclo	Medir tempo de inferência em cenários iguais	Menor é melhor, mantendo qualidade
Memória GPU/RAM	Monitorar pico e média	Avaliar viabilidade local
Continuidade contextual	Questões sobre eventos anteriores sem repeti-los	Precisão e taxa de acerto
Robustez após reinício	Retomar a partir de checkpoint	Equivalência com execução contínua
Contaminação entre sessões	Alternar cenários independentes	Taxa de vazamento deve tender a zero

Tabela 2 — Métricas e protocolos de avaliação. Fonte: elaboração própria (2026).

Modelo de linguagem pré-treinado da família Mamba, baseado em modelo seletivo de espaço de estados (SSM). A proposta não pressupõe treinamento supervisionado novo: é inicialmente um estudo experimental de inferência e memória recorrente. Serão comparadas condições de estado zerado, burn-in contextual com memórias recentes e restauração do estado anterior. Uma inicialização inspirada em HiPPO só será testada se compatível com a implementação escolhida. O ChromaDB permanece como memória episódica externa. A interface de inferência deve expor o estado para serialização e isolamento entre sessões.

3.1. Referencial teórico

Modelos de espaço de estados seletivos, como o Mamba, processam sequências com dinâmica recorrente parametrizada, oferecendo uma alternativa à atenção quadrática em determinadas condições. Entretanto, o desempenho real depende da implementação, da tarefa, do hardware e do comprimento da sequência.

A persistência do estado entre chamadas é uma intervenção no sistema de inferência, não uma propriedade automática de qualquer serviço que exponha um modelo Mamba. Burn-in, restauração de estado e recuperação RAG devem ser isolados em experimentos para evitar atribuir ganhos a componentes diferentes.

Referências para completar com dados bibliográficos verificados: Gu e Dao, “Mamba: Linear-Time Sequence Modeling with Selective State Spaces” (2023); Gu et al., “HiPPO: Recurrent Memory with Optimal Polynomial Projections” (2020); artigo “Transforming Agency on the Mode of Existence of Large Language Models”, conforme material do grupo. Conferir autoria, ano, DOI e formatação ABNT antes da entrega.

O artigo “Transforming Agency on the Mode of Existence of Large Language Models”, citado nas anotações do grupo, discute individualidade, normatividade e assimetria interacional como dimensões relevantes para agência. Esses conceitos serão operacionalizados como hipóteses observáveis, sem assumir que persistência computacional demonstra consciência ou agência plena.

Mamba, apresentado por Gu e Dao, emprega mecanismos seletivos de espaço de estados para processar sequências. A possibilidade de reutilizar estados de inferência motiva testar continuidade entre ciclos; isso depende de suporte concreto do backend e não é garantido por interfaces comuns de geração de texto.

No Dante, o ChromaDB recupera memórias por similaridade semântica, e o diário registra reflexões. O estado recorrente proposto constitui outro mecanismo, potencialmente útil para continuidade funcional, mas sujeito a deriva, ruído e interferência entre sessões.

O burn-in oferece um contexto inicial ao processar memórias antes da observação atual. HiPPO é uma linha de pesquisa relacionada à representação de histórico em sistemas dinâmicos, não uma modificação automaticamente aplicável a qualquer Mamba. Os experimentos deverão separar esses fatores.

A avaliação comparará lembrança de eventos anteriores, consistência de prioridades, respostas a observações idênticas com históricos diferentes, latência, RAM/VRAM, reinicialização e privacidade. Resultados positivos indicariam ganhos funcionais, não prova de individualidade ontológica.

4. Elaboração do quadro do lean Canvas

O quadro de nove blocos está disponível no documento complementar. O valor central da pesquisa é disponibilizar uma arquitetura experimental reproduzível para testar continuidade de estado, não demonstrar consciência artificial. Público-alvo: pesquisadores, laboratórios acadêmicos e desenvolvedores de agentes locais.

O Lean Canvas específico do Dante–Mamba foi elaborado em arquivo Word complementar, contendo problema, solução, proposta de valor, segmentos, métricas, vantagem, canais, custos e sustentabilidade.

5. Proposta conceitual

Aplicação inicial em laboratório acadêmico da Fatec, com protótipo local e cenários controlados de observação. A validação ocorrerá por benchmarks comparativos com os Systems 1 e 2 existentes, usando roteiros repetíveis, testes de reinício e métricas de coerência temporal, custo e segurança. Potenciais beneficiários: pesquisadores de IA local, laboratórios de sistemas inteligentes e equipes que desenvolvem assistentes com memória persistente.

5.1 Repositório

Repositório GitHub: https://github.com/coldguto22/MinilA

6. Conclusões da primeira parte

A primeira etapa deverá estabelecer uma linha de base e critérios de aceitação objetivos. Qualquer melhoria observada será descrita como resultado funcional, com limitações e possíveis explicações alternativas. O experimento não constitui evidência suficiente de consciência, identidade subjetiva ou autonomia plena.

O Dante oferece uma base operacional para testar continuidade entre ciclos com OCR, reflexão, diário e memória persistente. O Mamba refinado é uma hipótese de arquitetura para complementar a recuperação externa com estado recorrente. A primeira etapa deverá verificar viabilidade do backend e estabelecer comparação reproduzível. Ainda não há evidência experimental de que a proposta resolva os critérios filosóficos de agência; o objetivo é mensurar seus efeitos funcionais.